

利用自监督测试时训练 实现分布偏移下的泛化

Yu Sun¹ Xiaolong Wang^{1,2} Zhuang Liu¹ John Miller¹ Alexei A. Efros¹ Moritz Hardt^{1,3}

摘要

本文提出测试时训练 (Test-Time Training), 这是一种在训练数据与测试数据来自不同分布时提升预测模型性能的通用方法。我们将单个无标签测试样本转化为一个自监督学习问题, 并在作出预测前通过这一问题更新模型参数。该方法还可以自然地扩展到在线数据流。我们的方法简单, 却在多种旨在评估分布偏移鲁棒性的图像分类基准上带来了性能提升。

1. 引言

众所周知, 监督学习在分布偏移下的泛化能力仍然薄弱。除非训练数据和测试数据来自同一分布, 否则即使看似微小的差异, 也足以使最先进的模型失效 (Recht et al., 2018)。对抗鲁棒性和领域适应只是现有范式中的两个例子: 它们利用拓扑结构, 或训练期间可获得的测试分布数据, 试图预先应对训练分布与测试分布之间的差异。我们探索了一种新的泛化思路: 不预先应对分布偏移, 而是在测试时从中学习。

我们从一个简单的观察出发。测试时给出的无标签测试样本 x , 为我们提供了有关其来源分布的线索。我们提出, 通过让模型参数 θ 依赖测试样本 x , 但不依赖其未知标签 y , 来利用这条关于测试分布的线索。可变决策边界 $\theta(x)$ 在理论上非常强大, 因为它摆脱了固定模型容量的限制 (进一步讨论见第A1节); 但在实践中, 如何设计从 x 到 $\theta(x)$ 的反馈机制带来了新的挑战, 本文只是对这些挑战的初步探索。

我们提出的测试时训练方法基于这一个测试样本 x 构造自监督学习问题, 并在测试时、作出预测之前更新 θ 。自监督学习使用辅助任务, 自动从无标签输入中生成标签。在实验中, 我们采用的任务是将每张输入图像旋转 90 度的整数倍, 并预测其旋转角度 (Gidaris et al.,

2018)。

这一方法也很容易修改, 以适用于标准监督学习设定之外的情形。如果多个测试样本以一个批次到达, 我们可以利用整个批次进行测试时训练。如果样本以在线数据流的形式到达, 我们可以通过保留参数状态获得进一步提升。毕竟, 预测很少只是一次性的事件。如果额外假设测试样本由相同或平滑变化的分布偏移产生, 那么在线版本可以成为一种自然的部署方式。

我们在多个标准基准的物体识别任务上, 通过实验验证了所提出的方法。这些基准包括具有不同类型和不同严重程度损坏的图像 (Hendrycks & Dietterich, 2019)、包含运动物体的视频帧 (Shankar et al., 2019), 以及由 (Recht et al., 2018) 收集的、具有未知分布偏移的新测试集。我们的算法在分布偏移下取得了显著提升, 同时保持了在原始分布上的性能。

在实验中, 我们与一个强基线 (标记为“联合训练”) 进行比较: 该基线在训练时同时使用监督学习和自监督学习, 但在测试时保持模型固定。近期研究表明, 训练时的自监督可以提升鲁棒性 (Hendrycks et al., 2019a); 我们的联合训练基线相当于该工作的改进实现。第5节对相关工作进行了全面回顾。

我们在第4节中通过理论研究补充实验结果, 并在一个凸模型上给出了测试时训练何时有效的一个直观充分条件; 粗略地说, 该条件要求两个任务的损失函数具有相关的梯度。

2. 方法

本节介绍所提出方法的算法细节。为约定记号, 考虑一个标准的 K 层神经网络, 其第 k 层参数为 θ_k 。堆叠参数向量 $\theta = (\theta_1, \dots, \theta_K)$ 确定了整个分类模型, 它在测试样本 (x, y) 上的损失函数为 $l_m(x, y; \theta)$ 。我们称之为主任务, 损失函数的下标也体现了这一点。

假设我们拥有从分布 P 中独立同分布采样得到的训练数据 $(x_1, y_1), \dots, (x_n, y_n)$ 。标准的经验风险最小化求解以下优化问题:

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n l_m(x_i, y_i; \theta). \quad (1)$$

项目网站: <https://test-time-training.github.io/>。

¹ 加利福尼亚大学伯克利分校 ² 加利福尼亚大学圣迭戈分校 ³ MH 是 Twitter 的有偿顾问。通信作者: Yu Sun <yusun@berkeley.edu>。

第 37 届国际机器学习大会论文集, 线上会议, PMLR 119, 2020。版权归作者所有 (2020)。中文翻译与排版: dot (2026); 译文未经原作者审阅。原文: Sun 等, 9229–9248 页; 按 CC BY 4.0 许可翻译。

我们的方法需要一个损失函数为 $l_s(x)$ 的自监督辅助任务。本文选择旋转预测任务 (Gidaris et al., 2018); 已有研究表明, 它是一种简单而有效的卷积神经网络特征学习任务。该任务仅需将 x 在图像平面内旋转 0、90、180 或 270 度, 并让模型通过一个四分类问题预测旋转角度。第5节中的其他自监督任务也可以用于我们的方法。

辅助任务共享模型的部分参数 $\theta_e = (\theta_1, \dots, \theta_\kappa)$, 共享范围截至某个 $\kappa \in \{1, \dots, K\}$ 。我们将这 κ 层称为共享特征提取器。辅助任务使用自己专属的任务参数 $\theta_s = (\theta'_{\kappa+1}, \dots, \theta'_K)$ 。我们将非共享参数 θ_s 称为自监督任务分支, 将 $\theta_m = (\theta_{\kappa+1}, \dots, \theta_K)$ 称为主任务分支。直观地说, 联合架构呈 Y 形, 由共享底部和两个分支组成。在实验中, 自监督任务分支与主任务分支采用相同的架构, 唯一的区别是: 两个任务的类别数不同, 因此最后一层的输出维度不同。

训练采用多任务学习的方式 (Caruana, 1997); 模型在来自 P 的同一批数据上同时学习两个任务。我们将两个任务的损失相加, 并对全部参数求梯度。因此, 联合训练问题为

$$\min_{\theta_e, \theta_m, \theta_s} \frac{1}{n} \sum_{i=1}^n l_m(x_i, y_i; \theta_m, \theta_e) + l_s(x_i; \theta_s, \theta_e). \quad (2)$$

下面介绍在单个测试样本 x 上进行测试时训练的标准版本。简言之, 测试时训练通过最小化 x 上的辅助任务损失, 微调共享特征提取器 θ_e 。这可以表述为

$$\min_{\theta_e} l_s(x; \theta_s, \theta_e). \quad (3)$$

记 θ_e^* 为式3的(近似)最小化解。随后, 模型使用更新后的参数 $\theta(x) = (\theta_e^*, \theta_m)$ 作出预测。实验表明, 在式3中仅对 θ_e 优化, 与同时对 θ_e 和 θ_s 优化, 两者的差异可以忽略不计。从理论上说, 只有当优化过程包含超过一步梯度更新时, 两者才会存在差异。

测试时训练自然也能受益于标准的数据增强技术。对每个测试样本 x , 我们执行与训练时数据增强完全相同的一组随机变换, 形成一个仅包含 x 的这些增强副本的批次, 用于测试时训练。

在线测试时训练。 在我们方法的标准版本中, 式3中的优化问题始终使用通过最小化式2得到的参数 $\theta = (\theta_e, \theta_s)$ 初始化。对 x 作出预测后, 便丢弃 θ_e^* 。在标准监督学习设定之外, 如果测试样本以在线方式依次到达, 在线版本同样求解式3中的优化问题, 以更新共享特征提取器 θ_e 。但在处理测试样本 x_t 时, θ 改为使用在上一个样本 x_{t-1} 上更新得到的 $\theta(x_{t-1})$ 初始化。这使得 $\theta(x_t)$ 不仅能够利用 x_t 中的分布信息, 也能够利用 $x_1, \dots, x_{t-1}$ 中的分布信息。

3. 实验结果

我们在三类分布偏移基准上, 对所提出方法的两个版本(标准版本和在线版本)进行实验, 下面按视觉层次由低到高的顺序介绍。代码已在项目网站上公开。

网络细节。 我们的架构和超参数在所有实验中保持一致。我们使用 ResNet (He et al., 2016b), 在 CIFAR-10 (Krizhevsky & Hinton, 2009) 和 ImageNet (Russakovsky et al., 2015) 上分别采用不同的结构 (26 层和 18 层)。CIFAR-10 数据集包含 50K 张训练图像和 10K 张测试图像。ImageNet 包含 1.2M 张训练图像, 其 50K 张验证图像被用作测试集。用于 CIFAR-10 的 ResNet 包含三个组, 每组内卷积层的通道数和特征图尺寸相同; 我们将分支点设在第二组末尾。用于 ImageNet 的 ResNet 包含四个组; 我们将分支点设在第三组末尾。

我们在架构中使用组归一化 (Group Normalization, GN) 代替批归一化 (Batch Normalization, BN), 因为已有研究表明, 用小批次训练时, 所估计的批次统计量不准确, 导致 BN 效果不佳 (Ioffe & Szegedy, 2015)。这一技术细节会影响测试时训练, 因为每个批次仅包含单张图像的(增强)副本。与 BN 不同, GN 不依赖批次大小, 并且在我们的基线上取得了相近的结果。为保证完整性, 我们在附录第A4节中报告了使用 BN 的结果。我们在第A4.5小节中, 将所用架构与 Hendrycks et al. (2018) 的架构直接进行了比较。

优化细节。 对于联合训练 (式2), 我们采用随机梯度下降, 并使用 (Huang et al., 2016; He et al., 2016a) 中的标准超参数。对于测试时训练 (式3), 我们采用随机梯度下降, 并将学习率设为训练阶段最后一个轮次的学习率, 在所有实验中均为 0.001。受 (He et al., 2018; Liu et al., 2018) 中实践的启发, 我们在测试时训练期间将权重衰减和动量设为零。对于标准版本的测试时训练, 我们执行十步梯度更新, 每一步使用由同一张图像独立生成的批次。对于在线版本的测试时训练, 每到达一张新图像, 我们只执行一步梯度更新。数据增强采用随机裁剪和随机水平翻转。关于本方法的计算问题, 见附录第A2节。在所有表格和图中, 仅物体识别任务指普通的 ResNet 模型 (除非另有说明, 均使用 GN); 联合训练指同时在主任务和自监督任务上训练; 并在测试时保持固定的模型; Hendrycks et al. (2019a) 提出了这一方法; 测试时训练 (TTT) 指第2节所述的标准版本; 在线测试时训练 (TTT-Online) 指在线版本, 当 x_t 从同一分布依次到达时, 它不会丢弃 $\theta(x_t)$ 。TTT-Online 的性能以整个测试集上的平均值计算; 在运行 TTT-Online 前, 我们始终会打乱测试集, 以避免样本顺序引入的影响。

3.1. 损坏图像上的物体识别

Hendrycks & Dietterich (2019) 提出使用 15 种损坏来评测物体识别的鲁棒性, 它们分为四大类: 噪声、模糊、天气和数字处理。每种损坏均有五个严重程度等级, 其




图1. CIFAR-10-C 上第5级损坏的测试错误率 (%)。我们将所提出的测试时训练 (TTT) 及其在线版本 (TTT-Online) 与两个基线进行比较：不使用自监督的物体识别，以及使用自监督、但在测试时保持模型固定的联合训练。TTT 优于这两个基线，而 TTT-Online 则取得了进一步提升。

中第5级最严重（详见附录中的细节和示例图像）。这些损坏作用于 CIFAR-10 和 ImageNet 测试集的副本，旨在尽可能逼真地模拟现实世界中的图像损坏。所得新测试集分别称为 CIFAR-10-C 和 ImageNet-C。这一基准要求在原始训练集上进行训练；损坏类型的多样性，应当使过度依赖特定损坏知识的方法难以在所有类型上都表现良好。对于在线测试时训练，我们将整个测试集视为输入图像流，每张图像到达时，都以在线方式对其进行更新和测试。

CIFAR-10-C。 图1展示了我们在第5级（最严重）损坏上的结果。第1–4级的结果见附录第A4节。在全部五个等级和15种损坏类型上，测试时训练的标准版本和在线版本均大幅优于仅物体识别任务基线。标准版本始终优于联合训练；在线版本则经常显著优于联合训练 (>10%)，即使有性能下降，其幅度也从未超过0.2%。具体而言，TTT-Online 在三种噪声类型上的改进均达到 >24%，在像素化上的改进达到38%。对于一个看似不稳定、反复利用单张图像的学习问题而言，这种一致性相当令人惊讶。

仅进行物体识别任务的 ResNet-26 基线在 CIFAR-10 原始测试集上的错误率为8.9%。联合训练基线实际上将原始测试集上的错误率降至8.1%。更令人惊讶的是，与许多以牺牲原始性能换取鲁棒性的方法不同，测试时训练在多次独立试验中，均将原始测试集上的错误率进一步降低了0.2%。这表明，我们的方法不必在专门性和通用性之间作取舍。

除了我们的方法，另一个值得注意的现象是：联合训练始终优于单任务基线，正如 Hendrycks et al. (2019a) 所发现的那样。Hendrycks & Dietterich (2019) 也在该基准上试验了其他多种训练方法，并指出对抗 logit 配对 (ALP) (Kannan et al., 2018) 是最有效的方法。附录给出了这一附加基线在 CIFAR-10-C 所有等级上的结果及其实现细节。尽管 ALP 在某些最严重的损坏下表现出令人惊讶的鲁棒性（尤其是三种噪声类型），但它在原始分布及某些损坏上（例如所有等级的对比度和雾）

产生了大得多的错误率（达到两倍），并且在损坏不太严重时显著降低性能（尤其是在第1–3级）；对于基于对抗训练的方法，这种权衡并不意外。

ImageNet-C。 图2展示了我们在第5级（最严重）损坏上的结果。对于这个数据集，我们使用准确率而非错误率，因为基线在大多数损坏上的性能都很低。总体趋势与 CIFAR-10-C 大致相同。标准版本的 TTT 始终优于基线和联合训练；在线版本仅在原始测试集上比基线低0.1%，而在许多损坏类型上都取得了显著提升（达到三倍以上）。

在图2下半部分，我们展示了随着测试图像增多，在线版本的准确率（在滑动窗口上取平均）如何变化。由于篇幅所限，我们展示了原始测试集上的曲线，并按原文中的顺序，每隔三个损坏类型展示一个。在原始测试集上，经过50,000个样本的更新后，性能并未呈现可见的变化趋势。在损坏图像上，经过10,000个样本后准确率已经显著提高，但接近50,000个样本结束时仍在上升，这表明如果有更多样本，还存在进一步提升的空间。从曲线来看，TTT-Online 虽然从未看到任何一个标签，其表现却如同我们正在测试集上训练一样。

与无监督领域适应的比较。 表1通过实验比较了在线测试时训练 (TTT-Online) 与利用自监督的无监督领域适应 (UDA-SS) (Sun et al., 2019)。后者与我们的方法在思想上相似，但它是针对无监督领域适应设定设计的（第5节综述了这一设定下的其他相关工作）。给定来自训练分布的有标签数据和来自测试分布的无标签数据，UDA-SS 希望通过同时在两种分布的数据上学习自监督任务（具体为旋转预测），找到能够为两个分布提取有效特征的不变表示。随后，它利用有标签数据，在该不变表示之上学习标签预测函数。在我们的实验中，提供给 UDA-SS 的无标签数据正是去除标签后的整个测试集本身。

由于 TTT-Online 只能从已经用于评测的无标签测试




图2. ImageNet-C 上第 5 级损坏的测试准确率 (%). 上半部分: 我们的方法 TTT 和 TTT-Online 在所有损坏类型上, 均显著优于两个基线。下半部分: 我们以包含 100 个样本的滑动窗口内的平均值展示 TTT-Online 的准确率; 随着评测样本增多 (横轴), TTT-Online 的泛化表现越来越好, 同时不损害其在原始分布上的性能。这里使用准确率而非错误率, 是因为基线在大多数损坏上的性能都很低。

样本中学习, 因此它在任何时刻获得的信息都少于 UDA-SS。从这个意义上说, UDA-SS 应被视为一个拥有额外信息的参照方法, 而不是基线。令人惊讶的是, TTT-Online 在 15 种损坏中的 13 种, 以及原始分布上, 都优于 UDA-SS。我们的解释是, UDA-SS 必须为两个分布寻找不变表示, 而 TTT-Online 只需调整表示, 使其适合当前测试分布。也就是说, TTT-Online 可以灵活地遗忘不再相关的训练分布表示。这表明, 在我们的设定中, 遗忘并无害处, 甚至可能值得加以利用。

逐渐变化的分布偏移。 在前面的实验中, 我们评测在线版本时假设: 测试输入 x_t ($t = 1 \dots n$) 均采样自同一测试分布 Q , 该测试分布可以不同于训练分布 P 。打乱后的测试集中的独立同分布样本, 确实满足这一假设。但在这里我们展示, 这一假设实际上可以放宽为允许 $x_t \sim Q_t$, 其中 Q_t 与 Q_{t+1} 接近 (以分布距离衡量)。我们将其称为逐渐变化的分布偏移假设。我们在 CIFAR-10-C 的三种噪声类型上模拟这类分布偏移并开展实验。对每种噪声类型, x_t 的损坏标准差为 σ_t , 而

$\sigma_1, \dots, \sigma_n$ 在第 1 级和第 5 级的标准差之间插值。因此, 随着对测试集的评测推进、 t 增大, x_t 的损坏程度也越来越严重。如图 3 所示, 在放宽后的假设下, TTT-Online 仍优于联合训练 (以及我们的标准版本), 并且在前两种噪声类型上甚至优于 UDA-SS。

3.2. 视频帧上的物体识别

鲁棒 ImageNet 视频分类 (VID-Robust) 数据集由 Shankar et al. (2019) 基于 ImageNet 视频检测数据集 (Rusakovsky et al., 2015) 构建, 旨在展示: 在 ImageNet (静态图像) 上训练的深度物体识别模型, 无法很好地适应视频帧。VID-Robust 数据集包含 30 个类别的 1109 组视频帧; 每组是一个短视频片段, 其中的帧与某个锚帧相似。我们报告的是锚帧上的结果。为将 ImageNet 的 1000 个类别映射到 VID-Robust 的 30 个类别, 我们使用 Shankar et al. (2019) 中的最大值转换函数。我们未针对视频作任何修改, 而是基于上一小节使用的同一个 ImageNet 模型, 将所提出的方法应用于 VID-Robust。

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
TTT-Online	8.2	25.8	22.6	30.6	14.6	34.4	18.3	17.1	20.0	18.0	16.9	11.2	15.6	21.6	18.1	21.2
UDA-SS	9.0	28.2	26.5	20.8	15.6	43.7	24.5	23.8	25.0	24.9	17.2	12.7	11.6	22.1	20.3	22.6

表 1. CIFAR-10-C 上第 5 级损坏的测试错误率 (%)。比较在线测试时训练 (TTT-Online) 与利用自监督的无监督领域适应 (UDA-SS) (Sun et al., 2019); 后者在训练期间可以访问整个 (无标签) 测试集。较低的错误率以粗体突出显示。表中使用了损坏名称的简写, 依次为: 原始测试集、高斯噪声、散粒噪声、脉冲噪声、散焦模糊、玻璃模糊、运动模糊、缩放模糊、雪、霜、雾、亮度、对比度、弹性变换、像素化和 JPEG 压缩。此处报告的 TTT-Online 数值与图 1 相同。完整表格见表 A2。




图 3. 分布逐渐变化时, CIFAR-10-C 上三种噪声类型的测试错误率 (%). 分布偏移的构造方式是: 沿横轴从左向右, 将每种噪声的标准差由小逐渐增大。随着样本噪声增强、测试集评测不断推进, 所有方法的错误率都会上升, 但在线测试时训练 (TTT-Online) 的斜率比联合训练更平缓。对于前两种噪声类型, TTT-Online 的结果也优于利用自监督的无监督领域适应 (UDA-SS) (Sun et al., 2019)。

准确率 (%)	飞机	鸟	汽车	狗	猫	马	船	平均
仅物体识别任务	67.9	35.8	42.6	14.7	52.0	42.0	66.7	41.4
联合训练 (Hendrycks et al., 2019a)	70.2	36.7	42.6	15.5	52.0	44.0	66.7	42.4
TTT (标准版本)	70.2	39.2	42.6	21.6	54.7	46.0	77.8	45.2
TTT-Online	70.2	39.2	42.6	22.4	54.7	46.0	77.8	45.4

表 2. 基于 (Shankar et al., 2019) 调整得到的 VID-Robust 中 CIFAR 类别的逐类及平均分类准确率 (%). 测试时训练 (TTT) 和在线测试时训练 (TTT-Online) 的平均表现优于两个基线, 并在“船”和“狗”类别上取得了较大提升; 与“飞机”等类别相比, 旋转任务在这些类别上更有意义 (示例图像见图 A7)。

分类准确率见表 3。

此外, 我们从 VID-Robust 中选取与 CIFAR-10 重合的七个类别, 并将这些视频帧缩放至 CIFAR-10 图像的尺寸, 作为上一小节中在 CIFAR-10 上训练的模型的新测试集。同样, 我们未作任何修改, 就将所提出的方法应用于该数据集。表 2 给出了结果, 并按类别分别列出。我们注意到, 测试时训练在飞机类别上没有带来提升, 于是检查了一些飞机样本 (图 A7), 发现大多数图像的两侧存在黑边, 为旋转预测提供了过于简单的线索。此外, 对于天空中的飞机图像, 即使是人类, 也往往无法判断图像是否被旋转。这说明, 我们的方法要求自监督任务既有明确定义, 又不能过于简单。

3.3. CIFAR-10.1: 未知分布偏移

CIFAR-10.1 (Recht et al., 2018) 是一个参照 CIFAR-10 构建、包含 2000 张图像的新测试集, 其类别和图像维度均完全相同, 并尽可能严格地遵循 CIFAR-10 原论文记载的数据集构建过程。其目的是研究两个测试集之间存在的分布偏移及其对物体识别的影响。作者测试的所有模型, 在 CIFAR-10.1 上的性能都较 CIFAR-10 大幅下降, 尽管人类无法察觉两者的差异, 且人类在两者上的准确率相同。这表明, 分布偏移既隐蔽又无处不在, 即使研究者竭力将其最小化, 也是如此。

从 CIFAR-10 到 CIFAR-10.1 的分布偏移构成了一个极其困难的问题。此前尚无工作能提升现有模型在这一新测试集上的性能, 原因可能在于: 1) 研究者甚至无法识别这些分布偏移, 更不用说用数学语言描述它们;




图4. 主任务 l_m 与自监督任务 l_e 关于共享特征提取器 θ_e 的梯度内积，与测试时训练带来的测试错误率改善（%）之间的散点图，分别对应标准版本（左）和在线版本（右）。每个点表示一个测试集上的平均值，每幅散点图包含 75 个测试集，涵盖第3.1小节所述的全部 15 种损坏类型及其五个等级。蓝色线条和色带分别表示最佳线性拟合及其 99% 置信区间。两个线性相关系数分别为 0.93 和 0.89，表明这两个量之间存在较强的正相关性，与定理 1 所揭示的结论一致。

方法	准确率 (%)
仅物体识别任务	62.7
联合训练 (Hendrycks et al., 2019a)	63.5
TTT (标准版本)	63.8
TTT-Online	64.3

表3. VID-Robust 数据集 (Shankar et al., 2019) 上的测试准确率 (%)。TTT 和 TTT-Online 均优于基线。

方法	错误率 (%)
仅物体识别任务	17.4
联合训练 (Hendrycks et al., 2019a)	16.7
TTT (标准版本)	15.9

表4. CIFAR-10.1 (Recht et al., 2018) 上的测试错误率 (%)。TTT 是首个能提升现有模型在这一新测试集上性能的方法。

2) CIFAR-10.1 中的样本直到测试时才会公开；即使在训练时公开，这些分布偏移也过于微妙，样本量也过小，难以进行领域适应 (Recht et al., 2018)。

在原始 CIFAR-10 测试集上，仅物体识别基线的错误率为 8.9%，联合训练基线的错误率为 8.1%；与表 4 的前两行相比，两者都出现了典型的性能下降（错误率约为两倍）。TTT 相比联合训练将错误率降低了 0.8%（相对改善 4.8%）。我们承认，相对于性能下降的幅度，这一改善较小；但对于这个极其困难的问题，我们认为这是令人鼓舞的第一步。

4. 理论结果

本节初步研究测试时训练何时有望奏效，以及为何能够奏效。对于凸模型，我们证明，损失函数之间的梯度正相关会使测试时训练后的主任务性能得到提升。基于这一认识，我们进一步通过实验表明，梯度相关性决定了测试时训练在第3节所讨论的深度学习模型上能否成功。

在陈述主要理论结果之前，我们先用一个简单模型说明其基本直觉。考虑一个回归问题，其中 $x \in \mathbb{R}^d$ 表示输入， $y_1 \in \mathbb{R}$ 表示标签，针对预测值 $\hat{y}$ ，目标函数为平方损失 $(\hat{y} - y_1)^2/2$ 。考虑一个由 $\mathbf{A} \in \mathbb{R}^{h \times d}$ 和 $\mathbf{v} \in \mathbb{R}^h$ 参数化的两层线性网络，其中 h 表示隐藏层的维数。该模型的预测为 $\hat{y} = \mathbf{v}^\top \mathbf{A}x$ ，主任务损失为

$$l_m(x, y_1; \mathbf{A}, \mathbf{v}) = \frac{1}{2} (y_1 - \mathbf{v}^\top \mathbf{A}x)^2. \quad (4)$$

此外，考虑一个同样使用平方损失的自监督回归任务，它为 x 自动生成标签 y_s 。设自监督任务头由 $\mathbf{w} \in \mathbb{R}^h$ 参数化，则自监督任务损失为

$$l_s(x, y_2; \mathbf{A}, \mathbf{w}) = \frac{1}{2} (y_2 - \mathbf{w}^\top \mathbf{A}x)^2. \quad (5)$$

现在，我们应用测试时训练，在 l_s 上执行一步梯度下降来更新共享特征提取器 $\mathbf{A}$ ；由于 y_2 已知，该梯度可以计算。由此得到

$$\mathbf{A}' \leftarrow \mathbf{A} - \eta (y_2 - \mathbf{w}^\top \mathbf{A}x) (-\mathbf{w}x^\top), \quad (6)$$

其中 $\mathbf{A}'$ 为更新后的矩阵， η 为学习率。如果令 $\eta = \eta^*$ ，其中

$$\eta^* = \frac{y_1 - \mathbf{v}^\top \mathbf{A}x}{(y_2 - \mathbf{w}^\top \mathbf{A}x) \mathbf{v}^\top \mathbf{w} x^\top x}, \quad (7)$$

那么, 通过简单的代数运算, 容易看出主任务损失 $l_m(x, y_1; \mathbf{A}', \mathbf{v}) = 0$ 。具体而言, 只要精心选择学习率, 测试时训练仅需一步梯度更新, 就能使主任务损失降为零。在实际应用中, 由于该学习率依赖未知的 y_1 , 其值也是未知的。不过, 由于我们的模型是凸的, 只要 η^* 为正, 将 η 设为一个足够小的正常数即可 (详见附录)。若 $x \neq 0$, 则在两个损失均非零时, 使 η^* 为正的一个充分条件是

$$\text{sign}(y_1 - \mathbf{v}^\top \mathbf{A}x) = \text{sign}(y_2 - \mathbf{w}^\top \mathbf{A}x) \quad (8)$$

$$\text{且 } \mathbf{v}^\top \mathbf{w} > 0. \quad (9)$$

对于这个简单模型, 上述条件的两个部分都有直观解释。第一部分表示两项任务的错误应当相关, 即两项任务的预测都向同一方向偏离真实值。第二部分 $\mathbf{v}^\top \mathbf{w} > 0$ 表示特征空间中的决策边界应当相关。事实上, 这两个部分成立, 当且仅当 $\langle \nabla l_m(\mathbf{A}), \nabla l_s(\mathbf{A}) \rangle > 0$ (这一事实的简单证明见附录)。总之, 如果梯度正相关, 测试时训练就能保证降低主任务损失。我们的主要理论结果将这一结论推广到一般的光滑凸损失函数。

定理 1. 设 $l_m(x, y; \theta)$ 表示参数为 θ 时在测试样本 x, y 上的主任务损失, $l_s(x; \theta)$ 表示仅依赖 x 的自监督任务损失。假设对于所有 x, y , $l_m(x, y; \theta)$ 关于 θ 可微、凸且 β -光滑, 并且对于所有 θ , 均有 $\|\nabla l_m(x, y; \theta)\|, \|\nabla l_s(x; \theta)\| \leq G$ 。采用固定学习率 $\eta = \frac{\epsilon}{\beta G^2}$, 对于满足

$$\langle \nabla l_m(x, y; \theta), \nabla l_s(x; \theta) \rangle > \epsilon, \quad (10)$$

的每一组 x, y , 都有

$$l_m(x, y; \theta) > l_m(x, y; \theta(x)), \quad (11)$$

其中 $\theta(x) = \theta - \eta \nabla l_s(x; \theta)$, 即采用一步梯度下降的测试时训练。

证明使用了优化中的标准方法, 详见附录。定理 1 揭示, 在光滑凸情形下, 梯度相关性是决定测试时训练成败的一个因素。在图 4 中, 我们针对第 3 节所用的深度学习模型和多种损坏类型, 通过实验表明, 这一认识也适用于非凸损失函数; 梯度相关性越强, 相对于基线的性能改善就越明显。

5. 相关工作

在测试样本上学习。 Shocher et al. (2018) 表明, 仅需尝试对输入图像的下采样版本进行上采样, 就能在测试时学习图像超分辨率, 这为我们的工作提供了重要启发。最近, Bau et al. (2019) 通过使预训练的 GAN 适应输入图像的统计特性, 改善了照片编辑效果。这一思想的较早实例之一来自 Jain & Learned-Miller (2011): 他们利用一幅图像中较易检测到的人脸, 逐步引导对同一图像中较难检测人脸的识别, 从而改进 Viola-Jones 人脸检测 (Viola et al., 2001)。我们算法的在线版本受到 Mullapudi et al. (2018) 的启发; 该工作让学生模型向

教师模型在线学习, 从而提高视频分割效率。Kalal et al. (2011) 也将在线更新的思想用于跟踪和检测。最近一项超声心动图研究 (Zhu et al., 2019) 通过序贯更新, 改进了用于跟踪心肌运动和心脏血流的深度学习模型。最后, 我们认同直推式学习 (Vapnik, 2013; Gammernan et al., 1998) 的理念, 但与其经典算法几乎没有共同之处; Tripuraneni & Mackey (2019) 近期在对 LASSO 估计量进行去偏的背景下, 从理论上探索了线性预测中的这一思想。

自监督学习 研究如何设计多种辅助任务, 从数据本身构造标签, 在无需人工标注的情况下学习语义信息, 例如上下文预测 (Doersch et al., 2015)、求解拼图 (Noroozi & Favaro, 2016)、图像着色 (Larsson et al., 2017; Zhang et al., 2016)、噪声预测 (Bojanowski & Joulin, 2017) 和特征聚类 (Caron et al., 2018)。本文采用旋转预测 (Gidaris et al., 2018)。Asano et al. (2019) 表明, 令人惊讶的是, 仅在一幅图像上进行自监督学习, 也能得到具有良好泛化能力的低层特征。与我们的工作密切相关的是, Hendrycks et al. (2019a) 提出, 联合训练主任务和自监督任务 (即第 3 节中的联合训练基线) 能够提高主任务的鲁棒性。相同思想也被用于少样本学习 (Su et al., 2019)、域泛化 (Carlucci et al., 2019) 和无监督域适应 (Sun et al., 2019)。

对抗鲁棒性 研究鲁棒风险 $R_{P, \Delta}(\theta) = \mathbb{E}_{x, y \sim P} \max_{\delta \in \Delta} l(x + \delta, y; \theta)$, 其中 l 是某个损失函数, Δ 为扰动集合; 通常将 Δ 取为 L_p 球, 其中 $p \in \{1, 2, \infty\}$ 。许多常用算法将其表述为鲁棒优化问题并求解 (Goodfellow et al., 2014; Madry et al., 2017; Sinha et al., 2017; Raghunathan et al., 2018; Wong & Kolter, 2017; Croce et al., 2018), 其中最为人熟知的技术是对抗训练。另一类工作基于随机平滑 (Cohen et al., 2019; Salman et al., 2019), 而包括输入变换 (Guo et al., 2017; Song et al., 2017) 在内的其他一些方法, 已被证明效果较弱 (Athalye et al., 2018)。上述方法主要存在两个问题。首先, 它们都可以被视为对决策边界进行平滑。这在理论上造成了准确率与鲁棒性之间的权衡 (Tsipras et al., 2018; Zhang et al., 2019); 我们在第 3 节的对抗训练基线实验中也观察到了这一现象。直观而言, Δ 越多样, 这种用一个边界应对所有情况的方法对于 Δ 中某个特定元素的效果就可能越差。其次, 对抗方法高度依赖 Δ 的数学结构, 而这种结构未必能够准确刻画现实世界中的扰动。因此, 在我们预先已知或能够进行数学建模的 Δ 之外, 泛化仍然困难, 对于非对抗性的分布偏移尤其如此。Kang et al. (2019) 的实验表明, 针对一个 Δ 的鲁棒性可能无法迁移到另一个扰动集合, 而在 L_∞ 球上进行训练, 实际上会损害在 L_1 球上的鲁棒性。

非对抗鲁棒性 研究损坏、扰动、分布外样本以及现实世界中的分布偏移所产生的影响 (Hendrycks et al., 2019b;a; 2018; Hendrycks & Gimpel, 2016)。Geirhos et al. (2018) 表明, 在受高斯噪声损坏的图像上训练, 能够使

深度学习模型对这种特定噪声具有鲁棒性，却不能提高其在受其他类型噪声（例如椒盐噪声）损坏的图像上的性能。

无监督域适应（又称迁移学习）研究这样一种分布偏移问题：训练时，除来自训练分布（源域）的有标签数据集之外，还可以获得来自测试分布（目标域）的无标签数据集 (Chen et al., 2011; Gong et al., 2012; Long et al., 2015; Ganin et al., 2016; Long et al., 2016; Tzeng et al., 2017; Hoffman et al., 2017; Csurka, 2017; Chen et al., 2018)。然而，这一问题设定的局限在于，泛化能力的改善可能仅限于这一特定的测试分布，而事先预见该分布可能很困难。已有工作尝试通过使用多个域以及持续演变的域，来预先覆盖更广泛的分布 (Hoffman et al., 2018; 2012; 2014)。测试时训练改变了无监督域适应的问题设定，不预先假定任何测试分布，同时从域适应算法中汲取灵感。本文是Sun et al. (2019) 的后续工作，我们在第3节中解释了二者的关系，并进行了实验比较。我们的更新规则可视为即时执行单样本无监督域适应；但需要注意，当目标域中仅有一个样本时，标准域适应技术的定义可能不再适用。

域泛化 研究这样一种设定：一个元分布生成多个环境分布，其中一部分环境在训练时可用（源环境），其余环境用于测试（目标环境） (Li et al., 2018; Shankar et al., 2018; Muandet et al., 2013; Balaji et al., 2018; Ghifary et al., 2015; Motiian et al., 2017; Li et al., 2017a; Gan et al., 2016)。当环境数量很少时，关于元分布的信息往往过于稀缺，难以发挥作用；当环境很多时，我们又回到了独立同分布的设定，每个环境都可以视为一个样本，此时一个有力的基线就是直接在所有环境上训练 (Li et al., 2019)。域泛化设定受到两个因素的限制：一是固定决策边界在专门性与通用性之间存在固有权衡；二是在元分布之外，即算法实际学到的 P 之外，泛化仍然难以实现。

单样本（少样本）学习 研究如何基于已经从多样化样本中学到的通用表征，仅使用一个（或少量）样本来学习新任务或新的分类类别 (Snell et al., 2017; Vinyals et al., 2016; Fei-Fei et al., 2006; Ravi & Larochelle, 2016; Li et al., 2017b; Finn et al., 2017; Gidaris & Komodakis, 2018)。我们的更新规则可以视为执行单样本自监督学习，并有望受益于单样本学习的进展而得到改进。

持续学习（又称无遗忘学习）研究这样一种设定：让模型依次学习一系列任务，并在训练后续任务时不遗忘较早的任务 (Li & Hoiem, 2017; Lopez-Paz & Ranzato, 2017; Kirkpatrick et al., 2017; Santoro et al., 2016)。相比之下，在测试时训练中，我们并不担心遗忘过去的测试样本，因为对这些样本的评估已经完成；而且，如果某个过去的样本碰巧再次出现，它还会再经历一次测试时训练。此外，由于两个任务已经进行过联合训练，遗忘训练集带来的影响也很小。

在线学习（又称在线优化）是学习理论中一个得到广泛研究的领域 (Shalev-Shwartz et al., 2012; Hazan et al., 2016)。其基本设定反复执行以下过程：接收 x_t ，预测 $\hat{y}_t$ ，从最坏情形预言机接收 y_t ，然后进行学习。最终性能通过遗憾值来评估；通俗地说，它衡量的是在线学习算法相对于事后选定的最优固定模型，性能差了多少。相比之下，我们的设定在测试期间始终不会揭示任何 y_t ，即使在线版本也是如此，因此我们无需引入最坏情形预言机或遗憾值的概念。此外，由于预测后无法获得环境反馈，我们的算法选择在预测 $\hat{y}_t$ 之前进行学习（使用自监督），而不是在预测之后。需要注意，上文介绍的一些论文 (Hoffman et al., 2014; Jain & Learned-Miller, 2011; Mullapudi et al., 2018) 在学习理论设定之外使用了“在线学习”一词，因此这一术语可能具有多种含义。

6. 讨论

测试时训练的思想同样适用于分割、检测等其他任务，以及语音识别、自然语言处理等其他领域。对于在各自领域具有先验知识的机器学习实践者，可以利用其专业知识，为测试时训练设计更好的专用自监督任务。研究通用自监督任务的人员，也可以在目前广泛采用的预训练与微调评估基准之外，将测试时训练作为另一种评估基准。

更广泛地说，我们希望本文能鼓励研究者放弃在测试时使用固定决策边界这一自我施加的限制，甚至彻底放弃训练与测试之间人为划定的界限。我们的工作只是迈向一种新范式的一小步：在这种范式中，大量学习发生在模型部署之后。

致谢。 本研究得到 NSF 项目 1764033、DARPA 和 Berkeley DeepDrive 的资助。本文历经较长时间的研究与写作，并受益于与许多同事的交流，包括 Ben Recht 及其学生 Ludwig Schmidt、Vaishaal Shanker 和 Becca Roelofs；Ravi Teja Mullapudi、Achal Dave 和 Deva Ramanan；以及 Armin Askari、Allan Jabri、Ashish Kumar、Angjoo Kanazawa 和 Jitendra Malik。

参考文献

- Asano, Y. M., Rupperecht, C., 和 Vedaldi, A. 少量图像无监督特征学习的惊人有效性。 *arXiv 预印本 arXiv:1904.13132*, 2019.
- Athalye, A., Carlini, N., 和 Wagner, D. 混淆梯度带来虚假的安全感：绕过针对对抗样本的防御。 *arXiv 预印本 arXiv:1802.00420*, 2018.
- Balaji, Y., Sankaranarayanan, S., 和 Chellappa, R. Metareg：利用元正则化实现域泛化。载于 *神经信息处理系统进展*, 页码：998–1008, 2018.
- Bau, D., Strobel, H., Peebles, W., Wulff, J., Zhou, B., Zhu,

- J.-Y., 和 Torralba, A. 利用生成式图像先验进行语义照片编辑。ACM 图形学汇刊 (TOG), 38(4):59, 2019.
- Bojanowski, P. 和 Joulin, A. 通过预测噪声进行无监督学习。载于 第 34 届国际机器学习会议论文集——第 70 卷, 页码: 517–526. JMLR. org, 2017.
- Carlucci, F. M., D’Innocente, A., Bucci, S., Caputo, B., 和 Tommasi, T. 通过求解拼图实现域泛化。载于 IEEE 计算机视觉与模式识别会议论文集, 页码: 2229–2238, 2019.
- Caron, M., Bojanowski, P., Joulin, A., 和 Douze, M. 用于视觉特征无监督学习的深度聚类。载于 欧洲计算机视觉会议论文集 (ECCV), 页码: 132–149, 2018.
- Caruana, R. 多任务学习。机器学习, 28(1):41–75, 1997.
- Chen, M., Weinberger, K. Q., 和 Blitzer, J. 用于域适应的协同训练。载于 神经信息处理系统进展, 页码: 2456–2464, 2011.
- Chen, X., Sun, Y., Athiwaratkun, B., Cardie, C., 和 Weinberger, K. 用于跨语言情感分类的对抗深度平均网络。计算语言学协会汇刊, 6:557–570, 2018.
- Cohen, J. M., Rosenfeld, E., 和 Kolter, J. Z. 通过随机平滑获得可认证的对抗鲁棒性。arXiv 预印本 arXiv:1902.02918, 2019.
- Croce, F., Andriushchenko, M., 和 Hein, M. 通过最大化线性区域实现 relu 网络的可证明鲁棒性。arXiv 预印本 arXiv:1810.07481, 2018.
- Csurka, G. 面向视觉应用的域适应: 综合综述。arXiv 预印本 arXiv:1702.05374, 2017.
- Ding, G. W., Wang, L., 和 Jin, X. AdverTorch v0.1: 基于 pytorch 的对抗鲁棒性工具箱。arXiv 预印本 arXiv:1902.07623, 2019.
- Doersch, C., Gupta, A., 和 Efros, A. A. 通过上下文预测进行无监督视觉表征学习。载于 IEEE 国际计算机视觉会议论文集, 页码: 1422–1430, 2015.
- Fei-Fei, L., Fergus, R., 和 Perona, P. 物体类别的单样本学习。IEEE 模式分析与机器智能汇刊, 28(4):594–611, 2006.
- Finn, C., Abbeel, P., 和 Levine, S. 用于深度网络快速适应的模型无关元学习。载于 第 34 届国际机器学习会议论文集——第 70 卷, 页码: 1126–1135. JMLR. org, 2017.
- Gamerman, A., Vovk, V., 和 Vapnik, V. 通过直推进行学习。载于 第十四届人工智能中的不确定性会议论文集, 页码: 148–155. Morgan Kaufmann 出版公司, 1998.
- Gan, C., Yang, T., 和 Gong, B. 学习属性等价于多源域泛化。载于 IEEE 计算机视觉与模式识别会议论文集, 页码: 87–97, 2016.
- Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M., 和 Lempitsky, V. 神经网络的域对抗训练。机器学习研究杂志, 17(1):2096–2030, 2016.
- Geirhos, R., Temme, C. R., Rauber, J., Schütt, H. H., Bethge, M., 和 Wichmann, F. A. 人类与深度神经网络的泛化。载于 神经信息处理系统进展, 页码: 7538–7550, 2018.
- Ghifary, M., Bastiaan Kleijn, W., Zhang, M., 和 Balduzzi, D. 利用多任务自编码器实现物体识别的域泛化。载于 IEEE 国际计算机视觉会议论文集, 页码: 2551–2559, 2015.
- Gidaris, S. 和 Komodakis, N. 无遗忘的动态少样本视觉。载于 IEEE 计算机视觉与模式识别会议论文集, 页码: 4367–4375, 2018.
- Gidaris, S., Singh, P., 和 Komodakis, N. 通过预测图像旋转进行无监督表征学习。arXiv 预印本 arXiv:1803.07728, 2018.
- Gong, B., Shi, Y., Sha, F., 和 Grauman, K. 用于无监督域适应的测地流核。载于 2012 年 IEEE 计算机视觉与模式识别会议, 页码: 2066–2073. IEEE, 2012.
- Goodfellow, I. J., Shlens, J., 和 Szegedy, C. 解释并利用对抗样本。arXiv 预印本 arXiv:1412.6572, 2014.
- Guo, C., Rana, M., Cisse, M., 和 van der Maaten, L. 使用输入变换抵御对抗图像。arXiv 预印本 arXiv:1711.00117, 2017.
- Hazan, E. 等 在线凸优化导论。优化基础与趋势 @, 2 (3-4):157–325, 2016.
- He, K., Zhang, X., Ren, S., 和 Sun, J. 用于图像识别的深度残差学习。载于 IEEE 计算机视觉与模式识别会议论文集, 页码: 770–778, 2016a.
- He, K., Zhang, X., Ren, S., 和 Sun, J. 深度残差网络中的恒等映射。载于 欧洲计算机视觉会议, 页码: 630–645. Springer, 2016b.
- He, K., Girshick, R., 和 Dollár, P. 重新审视 imagenet 预训练。arXiv 预印本 arXiv:1811.08883, 2018.
- Hendrycks, D. 和 Dietterich, T. 针对常见损坏与扰动的神经网络鲁棒性基准评估。arXiv 预印本 arXiv:1903.12261, 2019.
- Hendrycks, D. 和 Gimpel, K. 用于检测神经网络中误分类样本和分布外样本的基线。arXiv 预印本 arXiv:1610.02136, 2016.

- Hendrycks, D., Mazeika, M., Wilson, D., 和 Gimpel, K. 利用可信数据, 在受严重噪声污染的标签上训练深度网络。载于 *神经信息处理系统进展*, 页码: 10456–10465, 2018.
- Hendrycks, D., Lee, K., 和 Mazeika, M. 使用预训练可以改善模型鲁棒性与不确定性。 *arXiv 预印本 arXiv:1901.09960*, 2019a.
- Hendrycks, D., Mazeika, M., Kadavath, S., 和 Song, D. 利用自监督学习改善模型鲁棒性与不确定性估计。 *arXiv 预印本*, 2019b.
- Hoffman, J., Kulis, B., Darrell, T., 和 Saenko, K. 为多源域适应发现潜在域。载于 *欧洲计算机视觉会议*, 页码: 702–715. Springer, 2012.
- Hoffman, J., Darrell, T., 和 Saenko, K. 基于连续流形的适应方法, 用于持续演变的视觉域。载于 *IEEE 计算机视觉与模式识别会议论文集*, 页码: 867–874, 2014.
- Hoffman, J., Tzeng, E., Park, T., Zhu, J.-Y., Isola, P., Saenko, K., Efros, A. A., 和 Darrell, T. Cycada: 循环一致的对抗域适应。 *arXiv 预印本 arXiv:1711.03213*, 2017.
- Hoffman, J., Mohri, M., 和 Zhang, N. 多源适应的算法与理论。载于 *神经信息处理系统进展*, 页码: 8246–8256, 2018.
- Huang, G., Sun, Y., Liu, Z., Sedra, D., 和 Weinberger, K. Q. 具有随机深度的深度网络。载于 *欧洲计算机视觉会议*, 页码: 646–661. Springer, 2016.
- Ioffe, S. 和 Szegedy, C. 批归一化: 通过减少内部协变量偏移加速深度网络训练。 *arXiv 预印本 arXiv:1502.03167*, 2015.
- Jain, V. 和 Learned-Miller, E. 预训练级联分类器的在线域适应。载于 *CVPR 2011*, 页码: 577–584. IEEE, 2011.
- Kalal, Z., Mikolajczyk, K., 和 Matas, J. 跟踪—学习—检测。 *IEEE 模式分析与机器智能汇刊*, 34(7):1409–1422, 2011.
- Kang, D., Sun, Y., Brown, T., Hendrycks, D., 和 Steinhardt, J. 不同扰动类型之间的对抗鲁棒性迁移。 *arXiv 预印本 arXiv:1905.01034*, 2019.
- Kannan, H., Kurakin, A., 和 Goodfellow, I. 对抗对数几率配对。 *arXiv 预印本 arXiv:1803.06373*, 2018.
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., 等 克服神经网络中的灾难性遗忘。 *美国国家科学院院刊*, 114(13):3521–3526, 2017.
- Krizhevsky, A. 和 Hinton, G. 从微小图像中学习多层特征。技术报告, Citeseer, 2009.
- Larsson, G., Maire, M., 和 Shakhnarovich, G. 将着色作为视觉理解的代理任务。载于 *CVPR*, 2017.
- Li, D., Yang, Y., Song, Y.-Z., 和 Hospedales, T. M. 更深、更广且更具艺术性的域泛化。载于 *IEEE 国际计算机视觉会议论文集*, 页码: 5542–5550, 2017a.
- Li, D., Zhang, J., Yang, Y., Liu, C., Song, Y.-Z., 和 Hospedales, T. M. 用于域泛化的情景式训练。 *arXiv 预印本 arXiv:1902.00113*, 2019.
- Li, Y., Tian, X., Gong, M., Liu, Y., Liu, T., Zhang, K., 和 Tao, D. 通过条件不变对抗网络实现深度域泛化。载于 *欧洲计算机视觉会议论文集 (ECCV)*, 页码: 624–639, 2018.
- Li, Z. 和 Hoiem, D. 无遗忘学习。 *IEEE 模式分析与机器智能汇刊*, 40(12):2935–2947, 2017.
- Li, Z., Zhou, F., Chen, F., 和 Li, H. Meta-sgd: 为少样本学习而学会快速学习。 *arXiv 预印本 arXiv:1707.09835*, 2017b.
- Liu, Z., Sun, M., Zhou, T., Huang, G., 和 Darrell, T. 重新审视网络剪枝的价值。 *arXiv 预印本 arXiv:1810.05270*, 2018.
- Long, M., Cao, Y., Wang, J., 和 Jordan, M. I. 利用深度适应网络学习可迁移特征。 *arXiv 预印本 arXiv:1502.02791*, 2015.
- Long, M., Zhu, H., Wang, J., 和 Jordan, M. I. 利用残差迁移网络进行无监督域适应。载于 *神经信息处理系统进展*, 页码: 136–144, 2016.
- Lopez-Paz, D. 和 Ranzato, M. 用于持续学习的梯度情景记忆。载于 *神经信息处理系统进展*, 页码: 6467–6476, 2017.
- Madry, A., Makelov, A., Schmidt, L., Tsipras, D., 和 Vladu, A. 迈向能够抵御对抗攻击的深度神经网络模型。 *arXiv 预印本 arXiv:1706.06083*, 2017.
- Motiian, S., Piccirilli, M., Adjeroh, D. A., 和 Doretto, G. 统一的深度监督域适应与泛化。载于 *IEEE 国际计算机视觉会议论文集*, 页码: 5715–5725, 2017.
- Muandet, K., Balduzzi, D., 和 Schölkopf, B. 通过不变特征表征实现域泛化。载于 *国际机器学习会议*, 页码: 10–18, 2013.
- Mullapudi, R. T., Chen, S., Zhang, K., Ramanan, D., 和 Fatahalian, K. 用于高效视频推理的在线模型蒸馏。 *arXiv 预印本 arXiv:1812.02699*, 2018.

- Noroozi, M. 和 Favaro, P. 通过求解拼图进行视觉表征的无监督学习。载于 *欧洲计算机视觉会议*, 页码: 69–84. Springer, 2016.
- Raghunathan, A., Steinhart, J., 和 Liang, P. 针对对抗样本的可认证防御。 *arXiv 预印本 arXiv:1801.09344*, 2018.
- Ravi, S. 和 Larochelle, H. 将优化作为少样本学习的模型。 *IEEE 模式分析与机器智能汇刊*, 2016.
- Recht, B., Roelofs, R., Schmidt, L., 和 Shankar, V. cifar-10 分类器能泛化到 cifar-10 吗? *arXiv 预印本 arXiv:1806.00451*, 2018.
- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., 和 Fei-Fei, L. ImageNet 大规模视觉识别挑战赛。 *国际计算机视觉杂志 (IJCV)*, 115(3): 211–252, 2015. doi: 10.1007/s11263-015-0816-y.
- Salman, H., Yang, G., Li, J., Zhang, P., Zhang, H., Razenshteyn, I., 和 Bubeck, S. 通过对抗训练的平滑分类器实现可证明鲁棒的深度学习。 *arXiv 预印本 arXiv:1906.04584*, 2019.
- Santoro, A., Bartunov, S., Botvinick, M., Wierstra, D., 和 Lillicrap, T. 利用记忆增强神经网络进行元学习。载于 *国际机器学习会议*, 页码: 1842–1850, 2016.
- Shalev-Shwartz, S. 等 在线学习与在线凸优化。 *机器学习基础与趋势* ④, 4(2):107–194, 2012.
- Shankar, S., Piratla, V., Chakrabarti, S., Chaudhuri, S., Jyothi, P., 和 Sarawagi, S. 通过交叉梯度训练实现跨域泛化。 *arXiv 预印本 arXiv:1804.10745*, 2018.
- Shankar, V., Dave, A., Roelofs, R., Ramanan, D., Recht, B., 和 Schmidt, L. 图像分类器能跨时间泛化吗? *arXiv*, 2019.
- Shocher, A., Cohen, N., 和 Irani, M. 利用深度内部学习实现“零样本”超分辨率。载于 *IEEE 计算机视觉与模式识别会议论文集*, 页码: 3118–3126, 2018.
- Sinha, A., Namkoong, H., 和 Duchi, J. 通过有理论依据的对抗训练认证一定程度的分布鲁棒性。 *arXiv 预印本 arXiv:1710.10571*, 2017.
- Snell, J., Swersky, K., 和 Zemel, R. 用于少样本学习的原型网络。载于 *神经信息处理系统进展*, 页码: 4077–4087, 2017.
- Song, Y., Kim, T., Nowozin, S., Ermon, S., 和 Kushman, N. Pixeldefend: 利用生成模型理解并防御对抗样本。 *arXiv 预印本 arXiv:1710.10766*, 2017.
- Su, J.-C., Maji, S., 和 Hariharan, B. 利用自监督增强少样本学习中的监督信号。 *arXiv 预印本 arXiv:1906.07079*, 2019.
- Sun, Y., Tzeng, E., Darrell, T., 和 Efros, A. A. 通过自监督进行无监督域适应。 *arXiv 预印本*, 2019.
- Tripuraneni, N. 和 Mackey, L. 线性预测的去偏。 *arXiv 预印本 arXiv:1908.02341*, 2019.
- Tsipras, D., Santurkar, S., Engstrom, L., Turner, A., 和 Madry, A. 鲁棒性可能与准确率相冲突。 *arXiv 预印本 arXiv:1805.12152*, 2018.
- Tzeng, E., Hoffman, J., Saenko, K., 和 Darrell, T. 对抗判别式域适应。载于 *IEEE 计算机视觉与模式识别会议论文集*, 页码: 7167–7176, 2017.
- Vapnik, V. *统计学习理论的本质*. Springer 科学与商业媒体, 2013.
- Vinyals, O., Blundell, C., Lillicrap, T., Wierstra, D., 等 用于单样本学习的匹配网络。载于 *神经信息处理系统进展*, 页码: 3630–3638, 2016.
- Viola, P., Jones, M., 等 利用简单特征的提升级联进行快速物体检测。 *CVPR (1)*, 1(511-518):3, 2001.
- Wong, E. 和 Kolter, J. Z. 通过凸外部对抗多面体实现针对对抗样本的可证明防御。 *arXiv 预印本 arXiv:1711.00851*, 2017.
- Zhang, H., Yu, Y., Jiao, J., Xing, E. P., Ghaoui, L. E., 和 Jordan, M. I. 有理论依据的鲁棒性与准确率权衡。 *arXiv 预印本 arXiv:1901.08573*, 2019.
- Zhang, R., Isola, P., 和 Efros, A. A. 多彩图像着色。载于 *欧洲计算机视觉会议*, 页码: 649–666. Springer, 2016.
- Zhu, W., Huang, Y., Vannan, M. A., Liu, S., Xu, D., Fan, W., Qian, Z., 和 Xie, X. 用于超声心动图密集跟踪的神经多尺度自监督配准。 *arXiv 预印本 arXiv:1906.07357*, 2019.

附录：利用自监督测试时训练 实现分布偏移下的泛化

A1. 关于可变决策边界的非形式化讨论

我们在引言中指出，在传统监督学习中， θ 给出的是固定决策边界，而我们的方法中的 θ 给出的是可变决策边界。这里对这一论断作非形式化讨论。

记输入空间为 $\mathcal{X}$ ，输出空间为 $\mathcal{Y}$ 。决策边界就是一个映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 。令 Θ 为一个模型类，例如 $\mathbb{R}^d$ 。现在考虑一族参数化函数 $g_\theta: \mathcal{X} \rightarrow \mathcal{Y}$ ，其中 $\theta \in \Theta$ 。在深度学习的语境下， g 是神经网络架构， θ 包含其参数。如果存在 $\theta \in \Theta$ ，使得对每个 $x \in \mathcal{X}$ 都有 $f(x) = g_\theta(x)$ ，我们就称 f 是相对于 g 和 Θ 的固定决策边界；如果对于每个 $x \in \mathcal{X}$ ，都存在 $\theta \in \Theta$ 使得 $f(x) = g_\theta(x)$ ，则称其为可变决策边界。注意，对于可变决策边界， θ 的选取可以依赖于 x ，而对于固定决策边界则不可以。由此很容易验证，在这些定义下，我们的论断成立。

持批判态度的读者可能会问：如果模型类可以任意大，难道不是每个决策边界都可以是固定的吗？确实如此，但问题并不止于此。令 $d = \dim(\mathcal{X}) \times \dim(\mathcal{Y})$ ，并考虑庞大的模型类 $\Theta' = \mathbb{R}^d$ ，它能够表示 $\mathcal{X}$ 与 $\mathcal{Y}$ 之间所有可能的映射。令 $g_{\theta'}$ 就是由 $\theta' \in \Theta'$ 表示的映射。那么，相对于 g 和 Θ 的可变决策边界，确实必然是相对于 g' 和 Θ' 的固定决策边界，但我们希望指出两点。第一，在没有任何先验知识的情况下，无论训练数据量有多大，只要它是有限的，就不可能在 Θ' 中实现泛化；从算法的角度看，对 g' 和 Θ' 进行推理很可能没有实际意义，而可变决策边界这一概念正是为了避免这种推理。第二，对于可变决策边界，根据 x 选取 θ 可以被视为在所有点 $x \in \mathbb{R}^d$ 上进行“训练”；然而，“训练”只在必要时发生，并且只针对实际遇到的 x 。

总之，可变决策边界这一概念不同于传统学习理论所能描述的情形。形式化讨论超出了本文的范围，但可能是未来工作中值得研究的方向。

A2. 本方法的计算开销

在测试时，我们的方法所需时间是常规测试的 $2 \times \text{批大小} \times \text{迭代次数}$ 倍，而常规测试对每个样本只进行一次前向传播。作为首项关于测试时训练的工作，本文更关注鲁棒性的提升，而非计算效率；不过，这里仍给出两种可能有用、但尚未得到充分验证的潜在解决方案。第一种是在 l_s 上使用阈值技巧，即方法部分为解决小批量问题而介绍的方法。对于实验中考察的模型，大约 80% 的测试样本低于阈值，因此只对其余 20% 的

样本进行测试时训练，对性能也不会有太大影响，因为这 20% 的样本包含了大多数预测错误的样本。第二种是减少测试时更新的迭代次数。对于在线版本，迭代次数已经是 1，因此没有进一步减少的空间。对于标准版本，我们做了一些初步实验，将迭代次数设为 1（而非 10），将学习率设为 0.01（而非 0.001），观察到其结果几乎与标准超参数设置一样好。关于效率的更深入讨论留待未来工作；未来或许可以在训练过程中，显式地使模型易于进行快速更新。

A3. 证明

本节证明正文中的理论结果。

A3.1. 简化示例问题

以下设定适用于两个引理；这正是我们简化示例问题的设定，为便于查阅，在此重述。

考虑一个两层线性网络，其参数为共享的 $A \in \mathbb{R}^{h \times d}$ ，以及分别用于两个任务头的固定参数 $v, w \in \mathbb{R}^h$ 。记输入为 $x \in \mathbb{R}^d$ ，两个任务的标签分别为 $y_1, y_2 \in \mathbb{R}$ 。对于主任务损失

$$l_m(A; v) = \frac{1}{2} (y_1 - v^\top A x)^2, \quad (12)$$

以及自监督任务损失

$$l_s(A; w) = \frac{1}{2} (y_2 - w^\top A x)^2, \quad (13)$$

测试时训练得到更新后的矩阵

$$A' \leftarrow A - \eta (y_2 - w^\top A x) (-w x^\top), \quad (14)$$

其中 η 为学习率。

引理 1. 沿用正文的推导，令

$$\eta^* = \frac{(y_1 - v^\top A x)}{(y_2 - w^\top A x) v^\top w x^\top x}. \quad (15)$$

假设存在某个 $\epsilon > 0$ ，使得 $\eta^* \in [\epsilon, \infty)$ 。那么，对于任意 $\eta \in (0, \epsilon]$ ，即可保证主任务损失减小，即 $l_m(A') < l_m(A)$ 。

证明. 根据正文中的推导可知，

$$l_m(A - \eta^* \nabla l_s A) = 0,$$

这一结果也可以通过简单的代数运算得到。于是，由凸性可得

$$l_m(\mathbf{A} - \eta \nabla l_s(\mathbf{A})) \quad (16)$$

$$= l_m\left(\left(1 - \frac{\eta}{\eta^*}\right) \mathbf{A} + \frac{\eta}{\eta^*} (\mathbf{A} - \eta^* \nabla l_s(\mathbf{A}))\right) \quad (17)$$

$$\leq \left(1 - \frac{\eta}{\eta^*}\right) l_m(\mathbf{A}) + 0 \quad (18)$$

$$\leq \left(1 - \frac{\eta}{\epsilon}\right) l_m(\mathbf{A}) \quad (19)$$

$$< l_m(\mathbf{A}), \quad (20)$$

最后一个不等式使用了 $l_m(\mathbf{A}) > 0$ 这一假设，而由于 $\eta^* > 0$ ，该假设成立。

引理 2. 定义 $\langle \mathbf{U}, \mathbf{V} \rangle = \text{vec}(\mathbf{U})^\top \text{vec}(\mathbf{V})$ ，即弗罗贝尼乌斯内积，则

$$\text{sign}(\eta^*) = \text{sign}(\langle \nabla l_m(\mathbf{A}), \nabla l_s(\mathbf{A}) \rangle). \quad (21)$$

证明. 通过简单的代数运算可得，

$$\begin{aligned} \langle \nabla l_m(\mathbf{A}), \nabla l_s(\mathbf{A}) \rangle &= \langle (y_1 - \mathbf{v}^\top \mathbf{A}x) (-\mathbf{v}x^\top), (y_2 - \mathbf{w}^\top \mathbf{A}x) (-\mathbf{w}x^\top) \rangle \\ &= (y_1 - \mathbf{v}^\top \mathbf{A}x) (y_2 - \mathbf{w}^\top \mathbf{A}x) \text{Tr}(\mathbf{x} \mathbf{v}^\top \mathbf{w} x^\top) \\ &= (y_1 - \mathbf{v}^\top \mathbf{A}x) (y_2 - \mathbf{w}^\top \mathbf{A}x) \mathbf{v}^\top \mathbf{w} x^\top x, \end{aligned}$$

其符号与 η^* 相同。

A3.2. 定理 1 的证明

对于任意 η ，由光滑性和凸性可得

$$\begin{aligned} l_m(x, y; \boldsymbol{\theta}(x)) &= l_m(x, y; \boldsymbol{\theta} - \eta \nabla l_s(x; \boldsymbol{\theta})) \\ &\leq l_m(x, y; \boldsymbol{\theta}) + \eta \langle \nabla l_m(x, y; \boldsymbol{\theta}), \nabla l_s(x, \boldsymbol{\theta}) \rangle \\ &\quad + \frac{\eta^2 \beta}{2} \|\nabla l_s(x; \boldsymbol{\theta})\|^2. \end{aligned}$$

记

$$\eta^* = \frac{\langle \nabla l_m(x, y; \boldsymbol{\theta}), \nabla l_s(x, \boldsymbol{\theta}) \rangle}{\beta \|\nabla l_s(x; \boldsymbol{\theta})\|^2}.$$

则式 22 变为

$$l_m(x, y; \boldsymbol{\theta} - \eta^* \nabla l_s(x; \boldsymbol{\theta})) \quad (22)$$

$$\leq l_m(x, y; \boldsymbol{\theta}) - \frac{\langle \nabla l_m(x, y; \boldsymbol{\theta}), \nabla l_s(x, \boldsymbol{\theta}) \rangle^2}{2\beta \|\nabla l_s(x; \boldsymbol{\theta})\|^2}. \quad (23)$$

再根据我们关于梯度范数和梯度内积的假设，

$$l_m(x, y; \boldsymbol{\theta}) - l_m(x, y; \boldsymbol{\theta} - \eta^* \nabla l_s(x; \boldsymbol{\theta})) \geq \frac{\epsilon^2}{2\beta G^2}. \quad (24)$$

由于实践中无法观测 η^* ，我们改用固定学习率 $\eta = \frac{\epsilon}{\beta G^2}$ ，如定理 1 所述。下面说明，这一固定学习率仍能改善主任务的性能。

根据我们的假设， $\eta^* \geq \frac{\epsilon}{\beta G^2}$ ，因此 $\eta \in (0, \eta^*]$ 。记 $\mathbf{g} = \nabla l_s(x; \boldsymbol{\theta})$ ，则由 l_m 的凸性可得

$$l_m(x, y; \boldsymbol{\theta}(x)) = l_m(x, y; \boldsymbol{\theta} - \eta \mathbf{g}) \quad (25)$$

$$= l_m\left(x, y; \left(1 - \frac{\eta}{\eta^*}\right) \boldsymbol{\theta} + \frac{\eta}{\eta^*} (\boldsymbol{\theta} - \eta^* \mathbf{g})\right) \quad (26)$$

$$\leq \left(1 - \frac{\eta}{\eta^*}\right) l_m(x, y; \boldsymbol{\theta}) + \frac{\eta}{\eta^*} l_m(x, y; \boldsymbol{\theta} - \eta^* \mathbf{g}) \quad (27)$$

结合式 24 可得

$$\begin{aligned} l_m(x, y; \boldsymbol{\theta}(x)) &\leq \left(1 - \frac{\eta}{\eta^*}\right) l_m(x, y; \boldsymbol{\theta}) \\ &\quad + \frac{\eta}{\eta^*} \left(l_m(x, y; \boldsymbol{\theta}) - \frac{\epsilon^2}{2\beta G^2}\right) \\ &= l_m(x, y; \boldsymbol{\theta}) - \frac{\eta}{\eta^*} \frac{\epsilon^2}{2\beta G^2} \end{aligned}$$

由于 $\eta/\eta^* > 0$ ，我们已经证明

$$l_m(x, y; \boldsymbol{\theta}) - l_m(x, y; \boldsymbol{\theta}(x)) > 0. \quad (28)$$

A4. 常见损坏数据集上的补充结果

为使表格简洁美观，我们使用以下缩写：B 表示基线，JT 表示联合训练，TTT 表示标准版本的测试时训练，TTT-Online 表示在线测试时训练，即在线版本。

我们还对损坏类型的名称作了简写，依次对应：原始测试集、高斯噪声、散粒噪声、脉冲噪声、散焦模糊、玻璃模糊、运动模糊、缩放模糊、雪、霜、雾、亮度、对比度、弹性变换、像素化和 JPEG 压缩。

A4.1. 采用批归一化的结果

如结果部分所述，批归一化 (BN) 对小批量无效，而测试时训练 (标准版本和在线版本均如此) 的输入正是小批量，因为构建每个批次时只有一个样本可用；因此，我们的主要结果基于采用组归一化 (GN) 的 ResNet。图 A2 和表 A1 展示了我们的方法在 CIFAR-10-C 的 5 级损坏上的结果，所用模型为采用批归一化 (BN) 的 ResNet。这些结果仅供感兴趣的读者参考。

在本项目的早期阶段，我们实验了两种解决 BN 小批量问题的潜在方案。一种朴素的方案是在测试时训练期间固定 BN 层，但这会减少共享参数，从而削弱性能增益。更好的方案是困难样本挖掘，下述结果采用的就是这一方案：我们不对所有输入都进行更新，而是只对自监督任务损失 l_s 较大的输入进行更新，因为在这些输入上获得的较大改善，或许能够抵消统计量不准确带来的负面影响。

采用 BN 时，测试时训练 (标准版本) 仍然非常有效。事实上，某些损坏类型上的改善相当显著，例如对比度 (34%)、散焦模糊 (18%) 和高斯噪声 (相较联合训练改善 22%，相较基线改善 16%)。原始分布上的性

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
B	7.9	63.9	58.8	64.3	46.3	54.6	41.6	45.9	31.9	44.0	37.5	13.0	69.2	33.8	61.4	31.7
JT	7.5	70.7	65.6	67.2	43.1	55.4	40.9	42.7	30.3	44.5	42.5	12.7	58.6	30.7	62.6	31.9
TTT	7.9	47.9	45.2	54.8	27.6	50.4	31.5	30.9	28.7	34.3	26.9	12.6	35.2	30.6	51.2	31.3

表 A1. CIFAR-10-C 上 5 级损坏的测试错误率 (%), 模型为采用批归一化的 ResNet-26。

能仍几乎不变; 实际上, 采用 BN 时原始分布上的错误率略低于采用 GN 时的错误率, 而且收敛所需的训练轮数仅为后者的一半。

我们没有继续开展 BN 实验, 原因有二: 1) 在线版本不适用于 BN, 因为在进行许多步 (例如 10000 步) 在线训练后, 批次统计量不准确的问题会加剧。2) 几乎每种损坏类型的基线错误率, 在采用 BN 时都显著高于采用 GN 时。尽管与本文的核心思想无关, 我们仍注意到一个有趣的现象: *GN* 显著提升了模型的鲁棒性。

A4.2. 补充基线: 对抗 logit 配对

如结果部分所述, Hendrycks & Dietterich (2019) 指出, 对抗 logit 配对 (ALP) (Kannan et al., 2018) 能够有效提升模型对损坏和扰动的鲁棒性, 尽管该方法最初旨在防御对抗攻击。我们在所有基于 CIFAR-10 的基准上 (采用 GN) 将 ALP 作为补充基线, 遵循 Kannan et al. (2018) 的训练流程以及其推荐的超参数。对抗攻击的实现来自 Ding et al. (2019) 的代码库。我们没有在 ImageNet 上运行 ALP, 因为我们就该方法引用的两篇论文, 即 Kannan et al. (2018) 和 Hendrycks & Dietterich (2019), 都未在 ImageNet 上运行该方法, 也未作出相关论断或建议。

A4.3. CIFAR-10-C 和 ImageNet-C 上的 5 级损坏结果

表 A2 和表 A3 对应结果部分的条形图。表 A2 中的两行已作为表 1 在正文中给出。

A4.4. CIFAR-10-C 上的 1-4 级损坏结果

下列条形图和表格给出了 CIFAR-10-C 上 1-4 级损坏的结果。所有损坏级别对应的原始分布都相同, 因此我们在原始分布上的结果也相同。

A4.5. 与 Hendrycks et al. (2019a) 的直接比较

一位匿名审稿人要求我们在最终版本中加入以下比较。我们的联合训练基线基于 Hendrycks et al. (2019a), 但也纳入了一些架构改动 (见下文)。我们发现, 这些改动提升了我们方法的鲁棒性, 并认为让基线同样受益十分重要。请注意, 我们的联合训练基线在整体上优于 Hendrycks 的方法: 将表 S2 与 Hendrycks et al. (2019a) 的图 3 (由该文作者提供) 进行比较, 我们的基线在所有损坏类型和损坏级别上的平均错误率为 22.8%, 而他们的平均错误率为 28.6%。

架构改动概述如下: 1) 使用组归一化 (GN) 替代批归一化 (BN)。为求完整, 表 S1 给出了采用 BN 的结果; 对照表 S2 中采用 GN 的结果可以看到, 无论是否使用自监督, GN 都显著提升了鲁棒性。2) 我们在第二个残差组之后分支, 而他们在第三个残差组之后、紧邻线性层之前分支。这始终带来约 0.5% - 1% 的改善。3) 我们使用 ResNet-26, 而他们使用 40-2 Wide ResNet。尽管我们的网络大小仅为他们的四分之一, 但得益于上述两项技巧, 我们的基线仍优于他们的方法。




图 A1. 常见损坏基准中的图像示例, 取自 Hendrycks & Dietterich (2019) 的原始论文。

利用自监督测试时训练实现分布偏移下的泛化




图 A2. CIFAR-10-C 上 5 级损坏的测试错误率 (%)，模型为采用批归一化的 ResNet-26。

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
B	8.9	50.5	47.2	56.1	23.7	51.7	24.3	26.3	25.6	34.4	28.1	13.5	25.0	27.4	55.8	29.8
JT	8.1	49.4	45.3	53.4	24.2	48.5	24.8	26.4	25.0	32.5	27.5	12.6	25.3	24.0	51.6	28.7
TTT	7.9	45.6	41.8	50.0	21.8	46.1	23.0	23.9	23.9	30.0	25.1	12.2	23.9	22.6	47.2	27.2
TTT-Online	8.2	25.8	22.6	30.6	14.6	34.4	18.3	17.1	20.0	18.0	16.9	11.2	15.6	21.6	18.1	21.2
UDA-SS	9.0	28.2	26.5	20.8	15.6	43.7	24.5	23.8	25.0	24.9	17.2	12.7	11.6	22.1	20.3	22.6
ALP	16.5	22.7	22.9	28.3	25.0	25.6	27.4	23.1	25.2	27.2	64.8	21.7	73.6	23.0	20.2	18.9

表 A2. CIFAR-10-C 上 5 级损坏的测试错误率 (%)，模型为 ResNet-26。

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
B	68.9	1.3	2.0	1.3	7.5	6.6	11.8	16.2	15.7	14.9	15.3	43.9	9.7	16.5	15.3	23.4
JT	69.1	2.1	3.1	2.1	8.7	6.7	12.3	16.0	15.3	15.8	17.0	45.3	11.0	18.4	19.7	22.9
TTT	69.0	3.1	4.5	3.5	10.1	6.8	13.5	18.5	17.1	17.9	20.0	47.0	14.4	20.9	22.8	25.3
TTT-Online	68.8	26.3	28.6	26.9	23.7	6.6	28.7	33.4	35.6	18.7	47.6	58.3	35.3	44.3	47.8	44.3

表 A3. ImageNet-C 上 5 级损坏的测试准确率 (%)，模型为 ResNet-18。




图 A3. CIFAR-10-C 上 4 级损坏的测试错误率 (%)。详情见结果部分。

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
B	8.9	46.4	39.2	44.8	15.3	52.5	19.1	20.5	21.3	26.9	13.3	10.5	13.7	20.8	35.3	26.9
JT	8.1	45.0	38.3	42.2	16.4	50.2	20.7	20.5	21.1	25.4	14.1	10.0	14.7	19.0	33.2	25.1
TTT	7.9	41.5	35.4	39.8	15.0	47.8	19.1	18.4	20.1	24.0	13.5	10.0	14.1	17.7	29.4	24.5
TTT-Online	8.2	22.9	20.0	23.9	11.2	35.1	15.6	13.8	18.6	15.9	12.3	9.7	11.9	16.7	13.6	19.8
ALP	16.5	21.3	20.5	24.5	20.7	25.9	23.7	21.4	24.2	23.9	42.2	17.5	53.7	22.1	19.1	18.5

表 A4. CIFAR-10-C 上 4 级损坏的测试错误率 (%)，模型为 ResNet-26。




图 A4. CIFAR-10-C 上 3 级损坏的测试错误率 (%)。详情见结果部分。

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
B	8.9	42.2	35.1	30.7	12.2	41.7	18.6	17.5	19.0	25.3	10.8	9.7	11.6	15.3	21.7	24.6
JT	8.1	40.2	34.4	29.9	12.2	37.9	20.8	17.3	18.4	25.0	11.4	9.2	12.0	15.2	20.8	22.8
TTT	7.9	37.2	31.6	28.6	11.5	35.8	19.1	15.8	17.8	23.3	11.0	9.1	11.6	14.3	18.9	22.3
TTT-Online	8.2	21.3	17.7	17.9	9.0	23.4	15.3	12.5	16.4	15.8	10.9	9.0	10.7	12.8	12.2	18.7
ALP	16.5	20.0	19.3	20.5	19.2	21.2	24.0	20.5	20.9	24.2	30.1	16.6	39.6	20.9	17.8	18.0

表 A5. CIFAR-10-C 上 3 级损坏的测试错误率 (%)，模型为 ResNet-26。




图 A5. CIFAR-10-C 上 2 级损坏的测试错误率 (%)。详情见结果部分。

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
B	8.9	31.7	22.6	24.3	9.9	42.6	14.9	14.7	21.7	18.4	9.8	9.1	10.0	13.1	17.1	22.4
JT	8.1	31.0	22.6	23.4	9.1	39.2	16.4	14.2	21.2	17.5	9.4	8.3	10.6	12.8	15.9	20.5
TTT	7.9	28.8	20.7	23.0	9.0	36.6	15.4	13.1	20.2	16.9	9.2	8.3	10.2	12.5	14.8	19.7
TTT-Online	8.2	16.8	13.8	15.5	8.5	23.4	13.3	11.5	16.8	12.7	9.4	8.4	9.7	12.4	11.5	17.0
ALP	16.5	18.0	17.2	19.0	17.8	20.7	21.2	19.3	19.0	20.1	22.4	16.3	29.2	20.3	17.4	17.8

表 A6. CIFAR-10-C 上 2 级损坏的测试错误率 (%)，模型为 ResNet-26。

	原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比	弹性	像素	JPEG
B	8.9	21.7	17.1	17.0	9.0	44.0	12.1	13.9	14.3	13.4	9.2	8.9	9.0	13.2	12.0	17.3
JT	8.1	20.4	16.6	16.9	8.2	40.5	12.2	13.0	13.1	12.3	8.4	8.1	8.5	12.9	11.3	15.9
TTT	7.9	19.1	15.8	16.5	8.0	37.9	11.7	12.2	12.8	11.9	8.2	8.0	8.3	12.6	11.1	15.5
TTT-Online	8.2	13.8	11.9	12.2	8.5	24.4	10.5	11.5	12.4	10.7	8.5	8.3	8.6	12.4	10.7	14.4
ALP	17.0	16.8	17.6	16.8	20.9	18.7	19.0	17.3	17.5	17.4	16.1	18.4	20.4	17.0	17.2	17.5

表 A7. CIFAR-10-C 上 1 级损坏的测试错误率 (%)，模型为 ResNet-26。




图 A6. CIFAR-10-C 上 1 级损坏的测试错误率 (%)。详情见结果部分。




图 A7. 结果一节中为适配 CIFAR-10 而处理的 VID-Robust 数据集样本图像 (Shankar et al., 2019)。每行展示一个类别的八幅样本图像。所示七个类别依次为：飞机、鸟、汽车、狗、猫、马、船。